

DOCUMENTAȚIE

ETL: Data Integration, Modelling & Reporting

Proiect - Dava.X Academy

Echipa de proiect: Buta Tudor
Butuza Maria
Criste Casian Stelian
Puiu Stefan
Samboan Miruna

Mentor: Iulia Maria Alecu
Buddy: Ionut Popescu

Cuprins

1 Introducere 3
1.1 Scopul proiectului 3
1.2 Obiectivele proiectului 3
1.3 Tehnologii utilizate 3
2 Contextul proiectului 4
3 Arhitectura soluției 4
3.1 Structura soluției 4
3.2 Arhitectura bazei de date 5
4 Sursele de date 5
5 Implementarea soluției 6
5.1 Implementarea bazei de date 6
5.2 Procesul ETL 6
6 Modelul dimensional (Star Schema) 7
6.1 Tabela de fapte 8
6.2 Tabelele de dimensiuni 9
6.3 Relațiile dintre tabele 9
7 Validarea datelor 9
7.1 Validarea datelor Timesheets 9
7.2 Validarea participării la training 10
7.3 Validarea absențelor 10
7.4 Validarea angajaților activi 11
8 Ghid de instalare și rulare 12
8.1 Cerințe software 12
8.2 Configurarea mediului 13
8.3 Crearea bazei de date 13
8.4 Executarea procesului ETL 13
9 Concluzii 14

1 Introducere

1.1 Scopul proiectului

Scopul acestui proiect este proiectarea și implementarea unui proces ETL (Extract - Transform - Load) pentru integrarea mai multor surse de date referitoare la activitatea angajaților într-un model analitic de tip Data Warehouse.

Procesul ETL permite colectarea datelor din surse independente, transformarea și standardizarea acestora, precum și încărcarea lor într-un model dimensional optimizat pentru interogări și raportare.

1.2 Obiectivele proiectului

Proiectul urmărește atingerea următoarelor obiective:

- integrarea datelor provenite din mai multe surse operaționale;
- implementarea unei arhitecturi ETL bazate pe schemele **src**, **stg** și **dwh**;
- transformarea și validarea datelor înainte de încărcarea în Data Warehouse;
- modelarea datelor utilizând o schemă de tip **Star Schema**;
- asigurarea unei structuri ușor de extins cu surse de date suplimentare;
- facilitarea interogării și raportării activităților angajaților.

1.3 Tehnologii utilizate

Pentru implementarea proiectului au fost utilizate următoarele tehnologii:

- Microsoft SQL Server 2025;
- SQL Server Management Studio (SSMS);
- Rancher Desktop;
- Git și GitHub pentru versionarea codului sursă;
- Microsoft Word pentru realizarea documentației proiectului.

2 Contextul proiectului

În cadrul companiei fictive **DavaX**, informațiile referitoare la activitatea angajaților sunt stocate în mai multe sisteme independente, fiecare având un rol specific. Aceste surse conțin date despre timpul lucrat, absențe, participarea la sesiuni de training și informații administrative despre angajați.

Lipsa unei surse unice de informații îngreunează analiza activității angajaților și generarea rapoartelor necesare procesului decizional. Din acest motiv, a fost implementat un proces ETL (Extract - Transform - Load) care integrează datele provenite din toate aceste surse și le transformă într-un model analitic unitar.

Rezultatul final este un **Data Warehouse** organizat sub forma unei **Star Schema**, care permite interogarea rapidă a informațiilor și realizarea rapoartelor privind activitatea angajaților.

3 Arhitectura soluției

Procesul ETL implementat în cadrul proiectului este organizat pe mai multe niveluri, fiecare având un rol bine definit în prelucrarea datelor. Datele sunt preluate din sursele de intrare, transformate și încărcate treptat într-un model dimensional optimizat pentru analiză și raportare.

3.1 Structura soluției

Proiectul este organizat în mai multe componente, fiecare având un rol bine definit în cadrul procesului ETL. Structura directorului principal este prezentată mai jos:

- **Raw**: conține fișierele sursă utilizate în procesul de încărcare a datelor.
- **Database**: include scripturile necesare pentru crearea bazei de date și a obiectelor SQL.
- **ETL**: conține scripturile responsabile pentru extragerea, transformarea și încărcarea datelor.
- **Documentation**: conține documentația tehnică a proiectului.
- **Reports & PowerBI**: conține interogările SQL utilizate pentru validare si vizualizare.

3.2 Arhitectura bazei de date

Baza de date este organizată în trei scheme principale:

1. **src (Source)** - conține datele importate din fișierele sursă, fără modificări asupra conținutului acestora.
2. **stg (Staging)** - reprezintă zona în care sunt realizate transformările, validările și standardizarea datelor înainte de încărcarea în modelul dimensional.
3. **dwh (Data Warehouse)** - conține modelul final de tip **Star Schema**, alcătuit din tabele de dimensiuni și tabela de fapte, utilizate pentru analiză și raportare.

Separarea datelor în aceste trei niveluri facilitează întreținerea procesului ETL, permite păstrarea datelor originale și simplifică extinderea soluției cu noi surse de date.

4 Sursele de date

În cadrul proiectului au fost utilizate mai multe surse de date independente, fiecare furnizând informații despre diferite aspecte ale activității angajaților. Aceste surse au fost integrate prin procesul ETL și utilizate pentru construirea modelului dimensional.

Datele au fost furnizate sub formă de fișiere CSV, fiecare reprezentând o categorie distinctă de informații. Înainte de încărcarea în baza de date, fișierele au fost analizate și prelucrate în cadrul procesului ETL.

Sursă	**Descriere**	**Date principale**
Timesheets	Evidența timpului lucrat de angajați	employee_id, work_date, project_name, hours_worked
Absences	Evidența absențelor	employee_id, absence_date, absence_type
Training Attendance	Participarea la sesiuni de training	training_id, employee_name, join_datetime, leave_datetime
Employee Master	Informații istorice despre angajați	grade, discipline, manager, DU
DU Exam Schedule	Programarea examenelor și absențelor	employee_id, activity_date, activity_code

Aceste surse sunt încărcate inițial în schema **src**, unde datele sunt păstrate în forma originală. Ulterior, în schema **stg**, sunt aplicate transformări și validări specifice fiecărei surse înainte de încărcarea în modelul dimensional.

5 Implementarea soluției

În cadrul proiectului a fost implementată o soluție ETL care permite integrarea datelor provenite din mai multe surse independente și încărcarea acestora într-un model dimensional destinat analizelor și raportării. Implementarea soluției este structurată în două componente principale: implementarea bazei de date și implementarea procesului ETL.

5.1 Implementarea bazei de date

Implementarea bazei de date a fost realizată în Microsoft SQL Server, utilizând scripturi SQL dedicate pentru crearea bazei de date, a schemelor și a obiectelor necesare procesului ETL.

Structura implementată include tabele specifice fiecărei etape a fluxului de prelucrare a datelor.

- În schema **src** au fost create tabelele utilizate pentru încărcarea datelor provenite din fișierele CSV, fiecare tabel corespunzând unei surse de date utilizate în proiect.
- În schema **stg** au fost create tabele destinate stocării datelor transformate și validate, împreună cu metadatele necesare monitorizării procesului de încărcare.
- În schema **dwh** au fost implementate tabelele de dimensiuni și tabela de fapte care alcătuiesc modelul dimensional utilizat pentru analiză și raportare.

Modelul bazei de date utilizează chei primare și chei externe pentru asigurarea integrității referențiale dintre tabele, iar relațiile dintre dimensiuni și tabela de fapte sunt implementate prin intermediul cheilor surrogate (*_sk).

5.2 Procesul ETL

Procesul ETL reprezintă componenta principală a soluției dezvoltate și are rolul de a prelua datele din sursele de intrare, de a le transforma și valida, iar ulterior de a le încărca în modelul dimensional al Data Warehouse-ului.

Implementarea procesului ETL a fost realizată prin intermediul a patru scripturi SQL, fiecare corespunzând unei etape distincte a fluxului de prelucrare a datelor:

Script	Rol
Load_Source.sql	Încarcă fișierele CSV în schema src prin BULK INSERT.
Load_Staging.sql	Curăță, validează și transformă datele.
Load_Dimensions.sql	Populează dimensiunile din schema dwh.
Load_Fact.sql	Populează tabela de fapte și leagă activitățile de dimensiuni.

Procesul ETL este executat secvențial, fiecare etapă utilizând rezultatele obținute în etapa precedentă. Această abordare asigură consistența datelor și facilitează identificarea eventualelor erori în timpul procesului de încărcare.

6 Modelul dimensional (Star Schema)

Modelul dimensional reprezintă nivelul final al procesului ETL și este implementat în schema **dwh**. Acesta este construit utilizând o arhitectură de tip **Star Schema**, optimizată pentru interogări analitice și raportare.

Modelul este alcătuit dintr-o tabelă de fapte și cinci tabele de dimensiuni, relaționate prin chei surrogate. Această structură facilitează analiza activității angajaților și permite obținerea rapidă a rapoartelor necesare procesului decisional.



Figura 6.1. Modelul dimensional implementat în schema dwh.

6.1 Tabela de fapte

Tabela **Fact_EmployeeActivity** reprezintă elementul central al modelului dimensional și stochează informațiile referitoare la activitatea desfășurată de angajați. Fiecare înregistrare descrie o activitate asociată unui angajat, unei date calendaristice, unui proiect și, după caz, unei sesiuni de training.

Tabela conține chei externe către toate dimensiunile modelului și măsura principală utilizată în analiză, respectiv numărul de ore lucrate (hours_worked).

6.2 Tabelele de dimensiuni

Modelul dimensional include cinci tabele de dimensiuni, fiecare având rolul de a descrie un anumit aspect al activității angajaților.

Dimensiune	**Rol**
Dim_Employee	Conține informațiile descriptive despre angajați și istoricul atributelor acestora.
Dim_Project	Conține lista proiectelor existente.
Dim_Date	Permite analiza datelor pe zile, luni și ani.
Dim_Training	Conține informații despre sesiunile de training.
Dim_ActivityType	Conține tipurile de activități (lucru, concediu, training etc.).

6.3 Relațiile dintre tabele

Tabela **Fact_EmployeeActivity** este conectată cu fiecare dintre dimensiuni prin intermediul cheilor surrogate (*_sk). Această abordare reduce redundanța datelor și permite efectuarea eficientă a analizelor multidimensionale.

Prin utilizarea modelului de tip **Star Schema**, informațiile pot fi agregate și filtrate cu ușurință în funcție de angajat, proiect, perioadă, tipul activității sau participarea la training.

7 Validarea datelor

Validarea datelor reprezintă o etapă esențială a procesului ETL, având rolul de a confirma că informațiile încărcate în Data Warehouse corespund datelor procesate în zona de Staging.

În cadrul proiectului au fost realizate mai multe verificări pentru a confirma integritatea și consistența datelor după executarea procesului ETL. Aceste validări au fost implementate prin interogări SQL care compară numărul de înregistrări dintre tabelele din schema stg și modelul dimensional din schema dwh.

7.1 Validarea datelor Timesheets

Prima verificare compară numărul de înregistrări din tabela *stg.Timesheets* cu numărul activităților de tip *Working* încărcate în tabela de fapte.

Scopul validării:

- verificarea încărcării complete a activităților de lucru în Data Warehouse;
- identificarea eventualelor înregistrări pierdute în timpul procesului ETL.

```
SELECT (SELECT COUNT(*) FROM stg.Timesheets) AS StagingRows,

(SELECT COUNT(*)

 FROM dwh.Fact_EmployeeActivity Activity INNER JOIN dwh.Dim_ActivityType ActivityType

    ON  Activity.activity_type_sk = ActivityType.activity_type_sk

 WHERE ActivityType.activity_type = 'Working') AS WarehouseRows;
```

7.2 Validarea participării la training

Această verificare compară numărul de înregistrări din tabela *stg.TrainingAttendance* cu numărul activităților de tip *Training* existente în tabela de fapte.

Scopul validării:

- confirmarea încărcării tuturor participărilor la training;
- verificarea corectitudinii transformărilor efectuate în etapa de staging.

```
SELECT

    (SELECT COUNT(*) FROM stg.TrainingAttendance) AS StagingRows,

    (SELECT COUNT(*)

     FROM dwh.Fact_EmployeeActivity Activity INNER JOIN dwh.Dim_ActivityType ActivityType
     ON Activity.activity_type_sk = ActivityType.activity_type_sk

     WHERE ActivityType.activity_type = 'Training') AS WarehouseRows;
```

7.3 Validarea absențelor

Pentru verificarea încărcării absențelor în modelul dimensional, a fost comparat numărul de înregistrări din tabela stg.Absences, la care se adaugă înregistrările de tip 'Absent' din stg.DUExamSchedule, cu activitățile de tip Absence existente în tabela de fapte. Categoria Absence din Data Warehouse agregă date din ambele surse.

Scopul validării:

- verificarea transferului complet al informațiilor privind absențele, din ambele surse;
- confirmarea clasificării corecte a tipurilor de activități.

```
SELECT

	((SELECT COUNT(*) FROM stg.Absences) +

	(SELECT COUNT(*) FROM stg.DUExamSchedule WHERE activity_code = 'Absent')) AS StagingRows,
	(SELECT COUNT(*)

	FROM dwh.Fact_EmployeeActivity Activity

	INNER JOIN dwh.Dim_ActivityType ActivityType

	ON Activity.activity_type_sk = ActivityType.activity_type_sk

	WHERE ActivityType.activity_type = 'Absence') AS WarehouseRows;;
```

7.4 Validarea examenelor

Această verificare compară numărul de înregistrări de tip `'Exam'` din `stg.DUExamSchedule` cu activitățile de tip `Exam` existente în tabela de fapte.

Scopul validării:

- confirmarea încărcării corecte a programărilor de examen;
- verificarea transformării matrice → tabelar pentru DU Exam Schedule.

```
SELECT

	(SELECT COUNT(*) FROM stg.DUExamSchedule WHERE activity_code = 'Exam') AS StagingRows,
	(SELECT COUNT(*)
	FROM dwh.Fact_EmployeeActivity Activity
	INNER JOIN dwh.Dim_ActivityType ActivityType
		ON Activity.activity_type_sk = ActivityType.activity_type_sk
	WHERE ActivityType.activity_type = 'Exam') AS WarehouseRows;
```

7.5 Validarea sărbătorilor legale

Această verificare compară numărul de înregistrări de tip 'Public Holiday' din stg.DUExamSchedule cu activitățile de tip Holiday existente în tabela de fapte.

Scopul validării:

- confirmarea încărcării corecte a zilelor libere legale.

```
SELECT

       (SELECT COUNT(*) FROM stg.DUExamSchedule WHERE activity_code = 'Public Holiday') AS
       StagingRows,
       (SELECT COUNT(*)
       FROM dwh.Fact_EmployeeActivity Activity
       INNER JOIN dwh.Dim_ActivityType ActivityType
              ON Activity.activity_type_sk = ActivityType.activity_type_sk

      WHERE ActivityType.activity_type = 'Holiday') AS WarehouseRows;
```

7.6 Validarea angajaților activi

Ultima verificare urmărește compararea numărului de angajați activi existenți în tabela *stg.EmployeeMaster* cu numărul angajaților activi încărcați în dimensiunea *Dim_Employee*.

Scopul validării:

- verificarea încărcării complete a dimensiunii angajaților;
- confirmarea implementării corecte a istoricului angajaților și a atributului is_current.

```
    SELECT

        (SELECT COUNT(*) FROM stg.EmployeeMaster WHERE is_current = 1)

    AS CurrentEmployees,

        (SELECT COUNT(*) FROM dwh.Dim_Employee WHERE is_current = 1)

       AS WarehouseEmployees;
```

În urma executării interogărilor de validare, s-a constatat că numărul de înregistrări din zona Staging corespunde cu datele încărcate în modelul dimensional. Acest rezultat confirmă funcționarea corectă a procesului ETL și integritatea datelor utilizate pentru raportare și analiză.

8 Ghid de instalare și rulare

8.1 Cerințe software

Pentru rularea proiectului au fost utilizate următoarele aplicații:

Software	**Versiune**
Rancher Desktop	Ultima versiune disponibilă
Microsoft SQL Server	SQL Server 2025
SQL Server Management Studio	SSMS
Git	Pentru versionarea codului sursă

8.2 Configurarea mediului

După clonarea repository-ului, a fost pornit un container Docker care găzduiește instanța SQL Server utilizată în cadrul proiectului. Pentru asigurarea persistenței datelor și accesului la fișierele sursă, au fost configurate volume dedicate pentru baza de date și pentru directorul care conține fișierele CSV.

```
docker run `
  --name sqlserver2025 `
  -e "ACCEPT_EULA=Y" `
  -e "MSSQL_SA_PASSWORD=parola " `
  -p 1433:1433 `
  -v sqlserver_data:/var/opt/mssql `
  -v "<calea_catre_folderul_cu_fisiere_CSV>:/var/opt/mssql/import" `
  -d mcr.microsoft.com/mssql/server:2025-latest
```

8.3 Crearea bazei de date

După conectarea la instanța SQL Server prin intermediul SQL Server Management Studio, au fost executate scripturile necesare pentru crearea bazei de date, a schemelor și a tabelelor.

Ordinea de execuție a scripturilor este prezentată în tabelul de mai jos.

Ordine	**Script**
1	01_CreateDatabase.sql
2	02_SourceSchema.sql
3	03_StagingSchema.sql
4	04_DWSchema.sql
5	Adding columns for DU table.sql

8.4 Executarea procesului ETL

După crearea bazei de date, procesul ETL a fost executat în următoarea ordine:

Ordine	**Script**
1	Load_Source.sql
2	Load_Staging.sql
3	Load_Dimensions.sql
4	Load_Fact.sql

Fiecare etapă utilizează rezultatele obținute în etapa precedentă, motiv pentru care respectarea ordinii de execuție este esențială pentru funcționarea corectă a procesului ETL.

La finalul procesului ETL au fost executate interogări de validare pentru verificarea încărcării corecte a datelor în modelul dimensional. Aceste verificări confirmă consistența informațiilor dintre zona de staging și Data Warehouse și asigură funcționarea corectă a soluției implementate.

9 Concluzii

În cadrul acestui proiect a fost proiectată și implementată o soluție ETL completă pentru integrarea și prelucrarea datelor provenite din mai multe surse independente. Prin utilizarea unei arhitecturi bazate pe schemele **src**, **stg** și **dwh**, datele au fost încărcate, transformate și organizate într-un model dimensional de tip **Star Schema**, optimizat pentru analiză și raportare.

Soluția implementată permite integrarea informațiilor referitoare la activitatea angajaților, absențe, participarea la sesiuni de training și informațiile administrative, oferind o imagine unitară asupra activității acestora. În plus, mecanismele de validare implementate confirmă consistența datelor și funcționarea corectă a procesului ETL.

Arhitectura proiectată este modulară și poate fi extinsă cu ușurință prin adăugarea unor noi surse de date sau prin dezvoltarea unor rapoarte și dashboard-uri suplimentare. De asemenea, separarea clară între zona de sursă, zona de transformare și modelul dimensional facilitează întreținerea și dezvoltarea ulterioară a soluției.

Prin implementarea acestui proiect au fost aplicate concepte specifice proceselor ETL și modelării dimensionale, precum încărcarea datelor din surse externe, transformarea și validarea informațiilor, utilizarea metadatelor de ingestie și proiectarea unui Data Warehouse destinat analizelor și raportării.